

**Modelo Predictivo de Supervivencia en el Siniestro del Titanic mediante Aprendizaje
Supervisado de Machine Learning**

Dominga Rodríguez

Maestría en Inteligencia Artificial y Aprendizaje Automático

Universidad Francisco Henríquez y Carvajal (UFHEC)

Materia: Aprendizaje Autónomo

Facilitador: [Nombre del Facilitador]

14 de julio de 2026

Introducción

El hundimiento del RMS Titanic en abril de 1912 sigue siendo uno de los desastres marítimos más trágicos e influyentes en la historia moderna. De los 2,224 pasajeros y tripulantes a bordo, más de 1,500 perdieron la vida cuando el barco chocó contra un iceberg en el Atlántico Norte. Esta catástrofe no solo conmocionó al mundo, sino que también impulsó reformas fundamentales en las regulaciones de seguridad marítima internacional, incluyendo la obligatoriedad de botes salvavidas suficientes para todas las personas a bordo.

Desde una perspectiva analítica y de ciencia de datos, el desastre del Titanic presenta un escenario de estudio único. A pesar de que el naufragio estuvo rodeado de caos y pánico, la supervivencia de los pasajeros no fue completamente aleatoria. Factores estructurales, normas sociales de la época (como el protocolo de "mujeres y niños primero"), la ubicación de los camarotes según la clase socioeconómica y la estructura del tamaño de las familias desempeñaron un papel decisivo en la determinación de quién sobrevivió y quién pereció.

El presente proyecto plantea el diseño y desarrollo de un modelo predictivo basado en Machine Learning Supervisado para estimar la probabilidad de supervivencia de un pasajero en función de sus características socio-demográficas y variables de viaje. Mediante la comparación de múltiples algoritmos supervisados de clasificación, este sistema busca modelar con precisión los patrones de mortalidad del naufragio, sirviendo como una demostración práctica de cómo los métodos predictivos pueden extraer conocimiento valioso de bases de datos históricas estructuradas.

Antecedentes

El análisis predictivo sobre los datos del Titanic se ha convertido en un punto de referencia (benchmark) fundamental en la literatura de la ciencia de datos y el aprendizaje

automático. Diversas investigaciones han explorado cómo variables específicas determinan las probabilidades de supervivencia, validando empíricamente las crónicas históricas del naufragio.

Estudios clásicos de sociología y economía del comportamiento, como los de Frey et al. (2011), confirman que las normas sociales de caballería ("mujeres y niños primero") y los incentivos de supervivencia interactuaron directamente con la clase socioeconómica del pasajero. Sus hallazgos demuestran que los pasajeros de primera clase tuvieron un acceso preferencial a los botes salvavidas, lo que se tradujo en una tasa de supervivencia significativamente superior en comparación con la tercera clase, donde el hacinamiento y la falta de información limitaron la evacuación.

Por otro lado, la aplicación de algoritmos modernos de clasificación sobre esta base de datos ha evidenciado que los modelos basados en árboles de decisión (como Random Forest y Gradient Boosting) superan a los modelos lineales al capturar interacciones complejas no lineales (por ejemplo, el efecto combinado de ser niño y viajar en tercera clase). Investigadores en computación educativa y analítica predictiva destacan que el dataset del Titanic permite ilustrar de manera transparente el impacto del preprocesamiento de datos (ETL) y el tratamiento de valores faltantes en la precisión final del modelo.

Definición del Problema y Pregunta de Investigación

Pregunta de Investigación Orientada a Machine Learning

¿Cómo optimizar la predicción de supervivencia de un pasajero del Titanic mediante un modelo de Machine Learning supervisado de clasificación binaria, utilizando variables demográficas y de viaje como el sexo, la edad, la clase de boleto, la tarifa y el tamaño de la familia?

Alcance de Predicción del Modelo

El modelo propuesto permitirá:

- **Predecir:** Si un pasajero sobrevivió (1) o no (0) al naufragio basándose en su perfil de datos.
- **Clasificar:** A los pasajeros en grupos de alta o baja probabilidad de supervivencia para auditar las disparidades del evento.
- **Identificar:** Qué variables (como la clase o el sexo) tuvieron el mayor peso o importancia predictiva en el desenlace del siniestro.

¿A quién impacta?

Este proyecto tiene un fuerte carácter didáctico y académico, impactando directamente a estudiantes y docentes de la Maestría en Inteligencia Artificial y Aprendizaje Automático en la Universidad Francisco Henríquez y Carvajal (UFHEC), al proporcionar un pipeline transparente y reproducible bajo la metodología de desarrollo de ciclo de vida CRISP-ML(Q).

Arquitectura del Modelo de Machine Learning y Decisiones

Variable Objetivo (Target)

Survived (Clasificación Binaria): 1 = Sobrevivió, 0 = No sobrevivió (Falleció).

Variables Independientes (Features)

Las variables independientes corresponden a las características del pasajero y su boleto:

- **Pclass:** Clase de Pasajero (1.^a, 2.^a o 3.^a clase). Proxy socioeconómico.
- **Sex:** Género del pasajero (male/female).
- **Age:** Edad del pasajero en años.

- **Fare:** Tarifa pagada por el boleto.
- **FamilySize:** Tamaño de la familia a bordo ($\text{SibSp} + \text{Parch} + 1$).
- **IsAlone:** Indicador de si viaja solo (1) o acompañado (0).
- **Embarked:** Puerto de Embarque (Cherbourg, Queenstown, Southampton).

Tabla 1*Arquitectura de Datos del Sistema y Decisiones Tecnológicas*

Componente	Descripción
Tipo de IA	Machine Learning Supervisado. El modelo aprende a partir de etiquetas reales de supervivencia.
Problema	Clasificación binaria (Clases: 1 / 0).
Algoritmo Principal	Random Forest Classifier (para interacciones complejas no lineales).
Algoritmo Base	Regresión Logística (para coeficientes matemáticos e inferencia en frontend JS).
Variables	Pclass, Sex, Age, SibSp, Parch, Fare, Embarked, FamilySize, IsAlone.
Métricas de Evaluación	Accuracy, Precision, Recall, F1-Score y AUC-ROC.
Herramientas	Python, Scikit-learn, Pandas, NumPy, Streamlit, HTML5/CSS3/JavaScript.

Justificación del Modelo Seleccionado

Se seleccionan Random Forest y Regresión Logística como los pilares del proyecto. El Random Forest es ideal para capturar las complejas interacciones no lineales de las variables demográficas en el barco (por ejemplo, el efecto del sexo combinado con la clase socioeconómica). La Regresión Logística, al proporcionar coeficientes numéricos explícitos y un cálculo de probabilidad directo mediante una sigmoide lineal, resulta óptima para el despliegue ligero en JavaScript cliente.

Datos Necesarios para el Desarrollo del Modelo

Tabla 2

Tipos de Datos Requeridos y Fuentes de Obtención

Tipo de dato	Descripción	Fuente de obtención	Tecnología / Formato
Datos Demográficos	Género, edad y estatus familiar del pasajero.	Dataset histórico del Titanic.	CSV (titanic.csv)
Datos de Viaje	Clase de cabina, puerto de embarque, tarifa y código de boleto.	Registros de la lista de pasajeros.	CSV / Pandas DataFrame

Datos y Analítica para la Toma de Decisiones

Proceso ETL (Extract, Transform, Load)

Extract: Extracción del manifiesto estructurado de pasajeros desde titanic.csv.

Transform: Imputación de edad mediante la mediana de grupos específicos (Pclass y Sex); imputación de embarque mediante moda. Creación de variables de ingeniería: FamilySize e IsAlone. Codificación binaria para Sex (0/1) y estandarización para variables continuas (Age, Fare).

Load: División estructurada del dataset en subconjuntos de entrenamiento (70%) y prueba (30%).

Análisis Exploratorio de Datos (EDA)

El EDA visual y estadístico confirmó la alta tasa de supervivencia en mujeres (74%) contra hombres (19%), así como el gradiente socioeconómico en la supervivencia (1.^a clase: 63%, 2.^a clase: 47%, 3.^a clase: 24%).

Planificación y Desafíos de la Gestión de Datos

Tabla 3

Desafíos Estratégicos de los Datos

Factor	Fortalezas	Oportunidades	Debilidades	Amenazas
Calidad de datos	Formato tabular limpio.	Aplicar técnicas de imputación avanzadas.	Faltantes sustanciales en Cabin.	Sesgo por imputación incorrecta de Age.
Sesgo de datos	Datos reales del hecho.	Analizar disparidades socio-demográficas históricas.	Desbalance moderado (61% fallecidos).	El modelo lineal puede ignorar factores no dominantes.

Tabla 4

Matriz DOFA – Gestión de Datos en el Proyecto Titanic

Fortalezas (F)	Debilidades (D)	Oportunidades (O)	Amenazas (A)
Registros tabulares bien estructurados y oficiales.	Datos históricos limitados que impiden recolectar nuevas muestras.	Uso académico para ilustrar sesgos sociales en algoritmos.	El sesgo de género inherente puede nublar la influencia de otras variables.

Objetivos y Dimensión Ética

Objetivos SMART

- **Específico:** Modelar la supervivencia binaria en el Titanic.
- **Medible:** Accuracy superior al 80% en validación de test.
- **Alcanzable:** Mediante el uso de Scikit-learn sobre el dataset original de 891 registros.
- **Relevante:** Ilustra el proceso completo de CRISP-ML(Q).
- **Temporal:** Desarrollado y finalizado dentro del cronograma lectivo.

Tabla 5*Consideraciones Éticas de la Plataforma*

Consideración ética	Enfoque de Mitigación	¿Aplica?
Dignidad e Identidad	Los nombres de los pasajeros se omiten del entrenamiento para evitar estigmatización y centrar el análisis en perfiles socio-demográficos.	Sí
Transparencia Algorítmica	Las reglas complejas del Random Forest se explican mediante la interpretabilidad de un Árbol de Decisión complementario.	Sí
Sesgo Histórico	Se expone explícitamente el sesgo de clase y género del naufragio para evitar replicarlo en la interpretación moderna.	Sí

Guía para el Elevator Pitch (5 minutos)

Tabla 6*Estructura de la Presentación de 5 Minutos*

Tiempo	Contenido de la presentación
Minuto 0–1: El problema	Presentación del naufragio y justificación de que la supervivencia no fue al azar.
Minuto 1–2: La solución	Uso de clasificación binaria (Random Forest y Regresión Logística) para modelar la supervivencia.
Minuto 2–3: Los datos	Tratamiento de nulos de edad, agregación del tamaño familiar e importancia de la tarifa.
Minuto 3–4: La ética	Transparencia del algoritmo y análisis del sesgo de clase y género histórico.
Minuto 4–5: El impacto	Visualización de las aplicaciones web e impacto pedagógico en UFHEC.

Análisis Crítico y Estratégico del Equipo

¿Cuál es el mayor desafío en su proyecto?

El mayor desafío es el sesgo histórico y el desbalance moderado. Dado que el protocolo "mujeres y niños primero" se aplicó con rigidez en las cubiertas superiores, la variable Sex tiene una importancia predictiva tan alta que los clasificadores simples tienden a ignorar las demás variables. Un hombre joven de 1.^a clase que pagó una tarifa muy alta y tenía acceso preferencial a los botes podría ser erróneamente clasificado como "No sobreviviente" debido al peso abrumador del factor de género en el modelo lineal.

¿Cómo lo mitigarían estratégicamente?

Para mitigar esto, implementamos modelos de ensamble no lineales como Random Forest y ajustamos los pesos de clase (`class_weight='balanced'`). Esto obliga al optimizador a prestar atención a las combinaciones complejas de variables (por ejemplo, pasajeros masculinos de primera clase que viajaban acompañados) y reduce la tasa de falsos negativos en hombres con condiciones socioeconómicas favorables para la supervivencia.

Referencias

- Frey, B. S., Savage, D. A., & Torgler, B. (2011). Behavior under extreme conditions: The Titanic disaster. *Journal of Economic Perspectives*, 25(1), 209–222.
<https://doi.org/10.1257/jep.25.1.209>
- Geron, A. (2019). *Hands-on Machine Learning with Scikit-Learn, Keras, and TensorFlow* (2nd ed.). O'Reilly Media.
- Hall, P., & Gill, N. (2019). *An introduction to machine learning interpretability* (2nd ed.). O'Reilly Media.

Anexos

Anexo 1: Datasets y Enlaces de Interés

Tabla 7

Datasets Recomendados y Enlaces de Kaggle

Nombre del dataset	Descripción	Variables útiles	Enlace
Titanic: Machine Learning from Disaster	Dataset oficial de Kaggle para modelar la supervivencia en el naufragio.	Survived, Pclass, Sex, Age, SibSp, Parch, Fare, Cabin, Embarked.	Kaggle
Titanic passenger list	Lista completa de pasajeros históricos del Titanic con detalles adicionales.	Passenger records, details, class.	Kaggle